



THUYẾT MINH

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN 2025

A. THÔNG TIN CHUNG

A1. Tên đề tài

- Tên tiếng Việt (IN HOA):
PHƯƠNG PHÁP KẾT HỢP NHIỀU MÔ HÌNH DỰA TRÊN TRANSFORMER CHO BÀI TOÁN PHÂN ĐOẠN NGỮ NGHĨA ẢNH
- Tên tiếng Anh (IN HOA):
AN ENSEMBLE LEARNING APPROACH FOR MULTIPLE TRANSFORMER-BASED SEMANTIC IMAGE SEGMENTATION MODELS

A2. Thời gian thực hiện

6 tháng (kể từ khi được duyệt).

A3. Tổng kinh phí

Tổng kinh phí: 6 triệu đồng, gồm:

- Kinh phí từ Trường Đại học Công nghệ Thông tin: 6 triệu đồng

A4. Chủ nhiệm

Họ và tên: Lương Hoàng Phát

Ngày, tháng, năm sinh: 25/09/2005

Giới tính (Nam/Nữ): Nam

Số CCCD: 060205002709

; Ngày cấp: 25/04/2021

;

Nơi cấp: Cục cảnh sát Bình Thuận

Mã số học viên: 24560012

Số điện thoại liên lạc: 0848837636

Khoa: Khoa Học Máy Tính

Số tài khoản: 0004100047404001

Ngân hàng: Phương Đông (OCB)

A5. Thành viên đề tài (kể cả CNĐT)

TT	Họ tên	MSHV	Khoa
1	Lương Hoàng Phát	24560012	Khoa học Máy tính

B. MÔ TẢ NGHIÊN CỨU

B1. Giới thiệu về đề tài

Giới thiệu bài toán: Phân đoạn ngữ nghĩa ảnh (Semantic Segmentation) là một bài toán cốt lõi của lĩnh vực thị giác máy tính, với mục tiêu gán nhãn lớp đối tượng cho từng điểm ảnh trong ảnh đầu vào. Đây là bước quan trọng để máy tính có thể "hiểu" nội dung hình ảnh ở mức chi tiết, và có nhiều ứng dụng thực tiễn như:

- **Xe tự hành (Autonomous Driving):** hỗ trợ hệ thống nhận diện và phân tách các thành phần như đường, xe cộ, người đi bộ, biển báo giao thông để đảm bảo khả năng điều hướng an toàn.
- **Giám sát giao thông thông minh (Intelligent Traffic Monitoring):** giúp phân tích lưu lượng phương tiện, nhận diện các hành vi bất thường.
- **Quy hoạch và quản lý đô thị (Urban Planning & Management):** tự động hoá quá trình phân tích ảnh viễn thám hoặc camera giám sát để hỗ trợ quản lý hạ tầng đô thị.



Hình 1: Đầu vào và đầu ra của bài toán

Lý do chọn đề tài: Semantic Segmentation có nhiều ứng dụng quan trọng trong đời sống hằng ngày như xe tự lái, quản lý giao thông, hay phân tích ảnh y tế. Trong những năm gần đây, nhiều mô hình phân đoạn ảnh đã được đề xuất, trong đó các kiến trúc CNN truyền thống (như FCN, U-Net, DeepLab) đã đạt được những thành tựu đáng kể. Tuy nhiên, chúng vẫn tồn tại hạn chế trong việc khai thác quan hệ dài hạn và ngữ cảnh toàn cục của ảnh. Sự ra đời của Transformer đã tạo nên bước tiến lớn nhờ cơ chế tự chú ý (self-attention), cho phép mô hình học được quan hệ toàn cục giữa các vùng ảnh. Mặc dù vậy, vẫn còn tồn tại một số thách thức:

- Chi phí tính toán cao khi áp dụng trên ảnh có độ phân giải lớn.
- Khó khăn trong việc biểu diễn chi tiết ở nhiều mức tỉ lệ, đặc biệt đối với các đối tượng nhỏ hoặc đa dạng kích thước.
- Các nghiên cứu hiện tại (như SegFormer [1], Swin Transformer [2]) tuy đã khai thác đa tỉ lệ, nhưng vẫn còn dư địa để cải thiện cả về độ chính xác và hiệu quả tính toán.

Do đó, việc nghiên cứu và đề xuất một phương pháp **Ensemble Learning cho việc kết hợp nhiều mô hình Transformer** là hết sức cần thiết [4], nhằm:

1. Kết hợp ưu điểm học ngữ cảnh toàn cục của Transformer với khả năng biểu diễn đa tỉ lệ, từ đó nâng cao chất lượng phân đoạn.
2. Giảm chi phí tính toán nhưng vẫn duy trì độ chính xác cao, phù hợp với các ứng dụng thực tế.
3. Kiểm chứng hiệu quả trên các bộ dữ liệu chuẩn (Cityscapes, CamVid), làm cơ sở cho các nghiên cứu tiếp theo trong lĩnh vực semantic segmentation.

B2. Mục tiêu, nội dung, kế hoạch nghiên cứu

B2.1 Mục tiêu

- Tìm hiểu và khảo sát các phương pháp hiện có trong bài toán phân đoạn ngữ nghĩa ảnh, đặc biệt là những mô hình dựa trên Transformer và Ensemble Learning, để thấy rõ ưu nhược điểm trong bối cảnh ảnh đường phố.
- Đề xuất phương pháp kết hợp nhiều mô hình dựa trên Transformer để phân đoạn ngữ nghĩa ảnh dựa trên phương pháp **Ensemble Learning**, nhằm:
 - Nắm bắt tốt hơn ngữ cảnh toàn cục và chi tiết cục bộ của ảnh đường phố.
 - Xử lý hiệu quả các đối tượng đa tỉ lệ (ví dụ: xe hơi lớn, người đi bộ nhỏ, biển báo nhỏ).
 - Giảm thiểu chi phí tính toán nhưng vẫn đảm bảo độ chính xác cao.
 - Kết hợp nhiều mô hình nhằm mục đích nâng cao hiệu suất nhưng vẫn giữ được mức chi phí tính toán hiệu quả
- Thực nghiệm và đánh giá mô hình trên các bộ dữ liệu chuẩn trong Semantic Segmentation cho urban scenes (Cityscapes, CamVid), sử dụng các độ đo như: Mean Intersection over Union (mIoU), Average Accuracy (aAcc), Mean Accuracy (mAcc).
- So sánh kết quả với các phương pháp hiện tại và phân tích khả năng ứng dụng trong các hệ thống thực tế bằng cách áp dụng trên các tập dữ liệu như camvid, cityscapes để giả lập môi trường thu thập từ xe tự hành.

B2.2 Nội dung và phương pháp nghiên cứu

Từ những vấn đề và hạn chế của các nghiên cứu liên quan, học viên đề xuất những nội dung và hướng nghiên cứu như sau:

Nội dung 1: Khảo sát, tìm hiểu các phương pháp phân đoạn ảnh và phương pháp kết hợp nhiều mô hình học cho ảnh đường phố

Phương pháp thực hiện:

- Nghiên cứu các phương pháp phân đoạn ảnh kinh điển dựa trên Transformer như: SegFormer [1], Mask2Former [5], FeedFormer [2], Swin Transformer [2].
- Khảo sát các kỹ thuật Ensemble Learning như: Bagging, Boosting, Stacking [4].
- Tổng hợp và phân tích ưu điểm, hạn chế của từng phương pháp khi áp dụng cho bối cảnh đô thị (Cityscapes, CamVid).
- Thực nghiệm bước đầu trên một số mô hình tiêu biểu để so sánh về độ chính xác (mIoU, mAcc, aAcc) và chi phí tính toán.

Kết quả dự kiến:

- Báo cáo tổng hợp lý thuyết về các phương pháp phân đoạn ảnh, và so sánh ưu điểm, hạn chế, độ phù hợp của từng phương pháp trong bài toán liên quan đến ảnh đường phố.
- Cơ sở để đề xuất phương pháp kết hợp nhiều mô hình dựa trên Transformer cho bài toán phân đoạn ngữ nghĩa ảnh.

Nội dung 2: Nghiên cứu, đề xuất phương pháp phân đoạn hình ảnh đa tỉ lệ kết hợp SegFormer với FeedFormer sử dụng Ensemble Learning

Phương pháp thực hiện:

- Nghiên cứu chi tiết kiến trúc SegFormer với MiT backbone và lightweight MLP decoder, FeedFormer với Transformer-based decoder khai thác quan hệ toàn cục và thông tin ngữ cảnh.
- Phân tích ưu nhược điểm của từng mô hình trong ảnh đường phố:

- **SegFormer [1]**: hiệu quả, tốc độ suy luận nhanh, nhưng hạn chế trong việc phân đoạn các đối tượng nhỏ hoặc có hình dạng phức tạp.
- **FeedFormer [2]**: biểu diễn tốt ngữ cảnh toàn cục, cải thiện khả năng nắm bắt quan hệ xa, nhưng chi phí tính toán cao hơn.
- Đề xuất phương pháp kết hợp hai mô hình bằng **Ensemble Learning** nhằm tận dụng ưu điểm của cả hai:
 - Trung bình trọng số (weighted averaging) trên output logits hoặc xác suất dự đoán.
 - Stacking/Learning-based fusion [4]: huấn luyện một bộ phân loại phụ (ví dụ logistic regression) trên output của cả hai mô hình để đưa ra quyết định tối ưu hơn.
 - Fusion theo không gian đa tỉ lệ: kết hợp feature maps ở nhiều mức tỉ lệ khác nhau để nâng cao khả năng nhận diện đối tượng kích thước đa dạng.
- Thực nghiệm so sánh các biến thể Ensemble, đánh giá bằng các chỉ số chuẩn (mIoU, mAcc, aAcc) trên bộ dữ liệu Cityscapes, từ đó lựa chọn cách kết hợp tối ưu giữa độ chính xác và chi phí tính toán.

Kết quả dự kiến:

- Xây dựng phương pháp Ensemble Learning cho việc kết hợp nhiều mô hình Transformer, kết hợp SegFormer và FeedFormer thông qua Ensemble Learning.
- Đạt kết quả thực nghiệm vượt trội so với từng mô hình gốc (SegFormer [1], FeedFormer [2]) và các baseline khác (Mask2Former [5], SegViT [3]), chứng minh hiệu quả của phương pháp Ensemble Learning.

Nội dung 3: Đánh giá phương pháp trên các bộ dữ liệu

Phương pháp nghiên cứu:

- Lựa chọn các bộ dữ liệu chuẩn cho phân đoạn ngữ nghĩa ảnh trong ảnh đường phố:
 - **Cityscapes**: bộ dữ liệu lớn, đa dạng về cảnh quan đường phố (xe, người đi bộ, tòa nhà, đường, cây xanh...).
 - **CamVid**: bộ dữ liệu giao thông đường phố với chú thích pixel-level, phù hợp cho kiểm chứng.
- Thực nghiệm phương pháp đề xuất sử dụng Ensemble Learning để kết hợp mô hình SegFormer [1] và FeedFormer [2], so sánh với các mô hình cơ sở (SegFormer [1], FeedFormer [2], SegViT [3], Mask2Former [5],...).
- Đánh giá kết quả dựa trên các độ đo chuẩn: Mean Intersection over Union (mIoU), Overall Accuracy (aAcc), Mean Accuracy (mAcc).
- Phân tích kết quả chi tiết:
 - Độ chính xác trên từng lớp (xe hơi, người, biển báo...).
 - Ảnh hưởng của đa tỉ lệ và Ensemble Learning tới các lớp nhỏ và khó phân đoạn.

Kết quả dự kiến:

- Báo cáo định lượng (mIoU, mAcc, aAcc) trên từng bộ dữ liệu, so sánh với baseline.
- Minh họa định tính: trực quan bằng hình ảnh phân đoạn ngữ nghĩa trên ảnh gốc, so sánh giữa mô hình đề xuất và mô hình cơ sở.
- Chứng minh hiệu quả và tính tổng quát của phương pháp Ensemble Learning cho việc kết hợp nhiều mô hình Transformer trong bối cảnh ảnh đường phố.

B2.3 Kế hoạch nghiên cứu

Nội dung	Thời gian dự kiến	Kết quả mong muốn
1	11/2025 - 12/2025	Tài liệu phân tích các phương pháp phân đoạn ảnh kinh điển, hiện đại, ưu và nhược điểm.
2	1/2026 - 02/2026	Phương pháp kết hợp kiến trúc SegFormer [1] với FeedFormer [2] sử dụng Ensemble Learning.
3	03/2026 - 04/2026	Bảng đánh giá phân tích phương pháp trên các bộ dữ liệu.

B3. Kết quả dự kiến

- Xây dựng và đề xuất một mô hình **Ensemble Learning** cho việc **kết hợp nhiều mô hình Transformer**, kết hợp ưu điểm của SegFormer [1] và FeedFormer [2] thông qua phương pháp Ensemble Learning.
- Báo cáo so sánh chi tiết giữa mô hình đề xuất và các mô hình cơ sở (SegFormer [1], FeedFormer [2]), cả về định lượng (mIoU, aAcc, mAcc) và định tính (hình ảnh minh họa).
- Cung cấp phân tích về tính khả thi của mô hình trong ứng dụng thực tế như xe tự hành, giám sát giao thông, và quản lý đô thị thông minh.

Tài liệu tham khảo

- [1] Xie, E., Wang, W., Yu, Z., Anandkumar, A., Alvarez, J. M., & Luo, P. (2021). SegFormer: Simple and efficient design for semantic segmentation with transformers. *Advances in neural information processing systems*, 34, 12077-12090. <https://arxiv.org/abs/2105.15203>.
- [2] Shim, J. H., Yu, H., Kong, K., & Kang, S. J. (2023, June). FeedFormer: Revisiting transformer decoder for efficient semantic segmentation. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 37, No. 2, pp. 2263-2271). <https://scispace.com/pdf/feedformer-revisiting-transformer-decoder-for-efficient-9rn1wkfp.pdf>.
- [3] Zhang, B., Tian, Z., Tang, Q., Chu, X., Wei, X., & Shen, C. (2022). Segvit: Semantic segmentation with plain vision transformers. *Advances in Neural Information Processing Systems*, 35, 4971-4982. https://proceedings.neurips.cc/paper_files/paper/2022/file/20189b1aaa8edbb6d8bd6c1067ab5f3f-Paper-Conference.pdf.
- [4] Chatzimpampas, A., Martins, R. M., Kucher, K., & Kerren, A. (2020). StackGenVis: Alignment of data, algorithms, and models for stacking ensemble learning using performance metrics. *IEEE Transactions on Visualization and Computer Graphics*, 27(2), 1547-1557. <https://ieeexplore.ieee.org/abstract/document/9222343>.
- [5] Cheng, B., Misra, I., Schwing, A. G., Kirillov, A., & Girdhar, R. (2022). Masked-attention mask transformer for universal image segmentation. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition* (pp. 1290-1299). <https://arxiv.org/abs/2112.01527>.

Ngày 07 tháng 10 năm 2025
Giảng viên hướng dẫn
(Ký và ghi rõ họ tên)

Nguyễn Thành Danh

Ngày 07 tháng 10 năm 2025
Chủ nhiệm đề tài
(Ký và ghi rõ họ tên)

Lương Hoàng Phát